

Relatório Técnico — HealthSearch

Desafio Integrador HealthSearch — Motor de Busca Híbrido com BM25 e Busca Semântica Vetorial Tendências em Ciência da Computação — Recuperação de Informação / PLN

1. Arquitetura da Solução

O HealthSearch foi implementado em um único arquivo Python utilizando Streamlit para a interface. O sistema mantém seis documentos de diretrizes médicas em memória e oferece três estratégias de recuperação: busca léxica com BM25, busca semântica por embeddings e fusão híbrida por Reciprocal Rank Fusion (RRF).

No pré-processamento, o texto é convertido para minúsculas, tem acentuação e caracteres especiais tratados, e passa por remoção de stopwords em português. A busca BM25 permite ajustar os parâmetros k_1 e b pela barra lateral.

Na busca semântica, o código tenta utilizar o modelo paraphrase-multilingual-MiniLM-L12-v2. Caso o modelo não esteja disponível, é utilizado um vetor simulado documentado no próprio código, permitindo executar a aplicação sem interromper a demonstração.

2. Fusão Híbrida por RRF

A estratégia híbrida utiliza somente as posições dos documentos em cada ranking, combinando BM25 e busca semântica. Com $k_{\text{rrf}} = 60$, o cálculo implementado é:

$$\text{Score_RRF}(D) = \alpha \times [1/(60 + \text{Rank_BM25})] + (1 - \alpha) \times [1/(60 + \text{Rank_Semântico})]$$

O parâmetro α é ajustável entre 0 e 1. O valor padrão da interface é 0,5, permitindo contribuição equivalente das duas fontes de ranking. O resultado é apresentado na aba Híbrido RRF.

3. Comparação dos Ranks

A aba Matriz Comparativa apresenta, para cada documento, as posições obtidas por BM25, pela busca semântica e pelo RRF. A aplicação também gera um gráfico de linhas com esses três rankings. Como os resultados dependem da consulta digitada pelo usuário e dos parâmetros selecionados, a matriz é recalculada dinamicamente.

Método	Base do ranking	Resultado exibido
BM25	Termos da consulta	Score e posição
Semântico	Similaridade entre embeddings	Similaridade e posição
RRF	Combinação dos ranks	Score RRF e posição

4. Interface e Funcionalidades

A interface possui quatro abas: Léxico, Semântico, Híbrido RRF e Matriz Comparativa. Na barra lateral, o usuário informa a consulta e ajusta k_1 , b e α . Há ainda uma opção de Cross-Encoder que, quando habilitada e disponível, reordena os três primeiros candidatos da busca híbrida.

5. Equipe

Aluno 1: Clayton Augusto Nascimento de Araújo

Aluno 2: Vitor Dias Cordeiro Sebadelhe

Aluno 3: Gabriel Gonzaga dos Santos Lopes

6. Conclusão

A implementação integra recuperação léxica e semântica em uma única interface, permitindo alterar os parâmetros, comparar rankings e observar o efeito da fusão RRF. O modo semântico possui fallback simulado para manter a aplicação executável quando os modelos externos não estiverem disponíveis.